De los datos a la predicción de demanda

3 fases: datos · modelo · despliegue | Tarea 01 + Fases 2 y 3

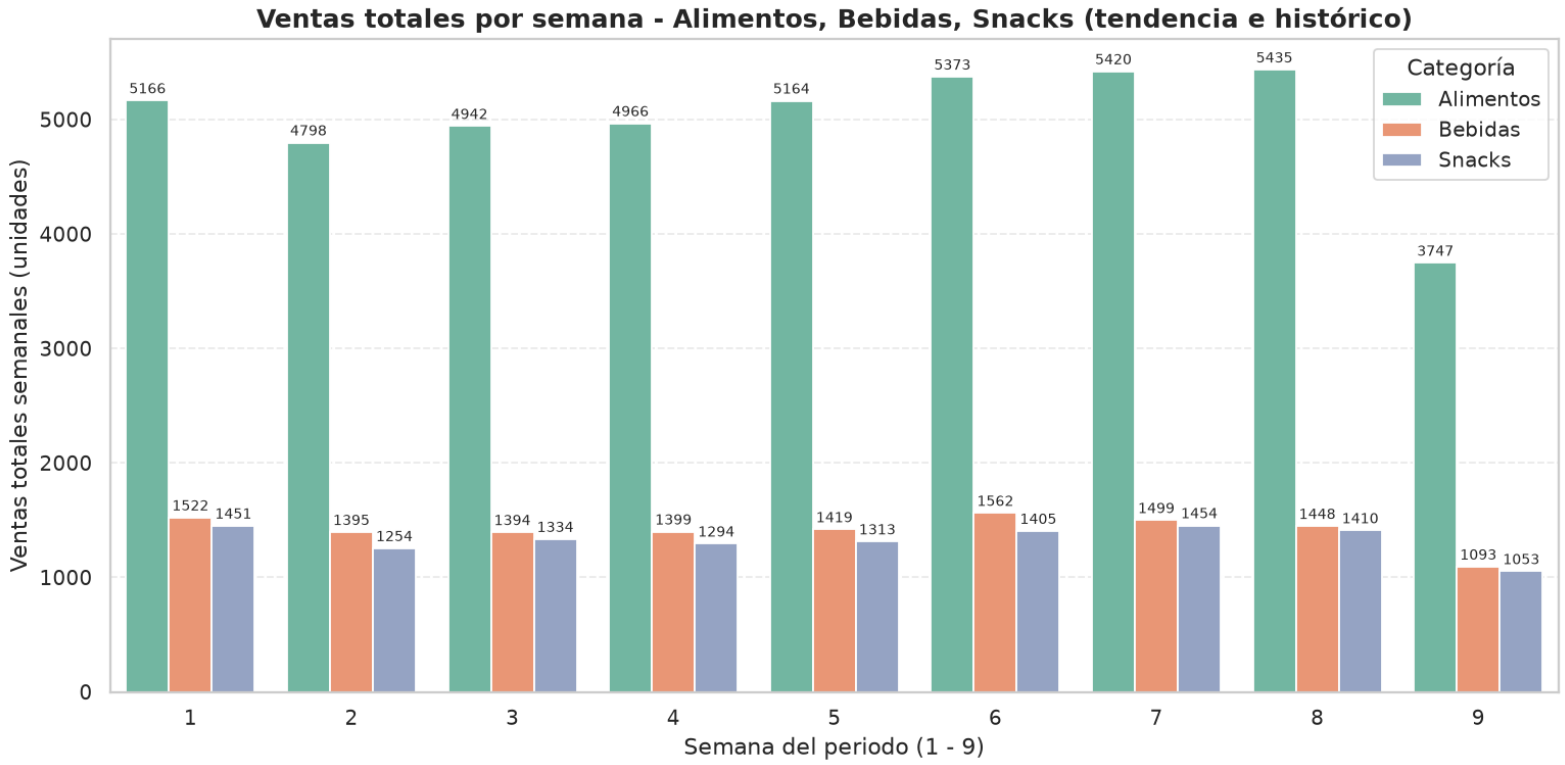
El problema y la propuesta

- Hoy la tienda repone 'a ojo': quiebres de stock en fin de semana y sobrestock entre semana.
- La demanda tiene patrón claro: fin de semana +55.6 % y feriados +40.1 %.
- Propuesta: predecir la demanda diaria por producto para decidir cuánto stock tener.
- Objetivo de negocio: menos quiebres, menos capital inmovilizado, mejor servicio.

FASE 1 · El dataset

- Origen: dataset público de Kaggle (Retail Store Inventory Forecasting).
- URL: https://www.kaggle.com/datasets/anirudhchauhan/retail-store-inventory-forecasting-dataset
- El dataset analizado es construido: 10 productos reales × 60 días (1 ene – 1 mar 2022).
- Modificaciones: español + productos reales, período de 2 meses, patrón semanal y feriados de Ecuador.
- Los datos del original son aleatorios (Holiday/Promotion no influye: 136.5 vs 136.4).

FASE 1 · Qué encontramos



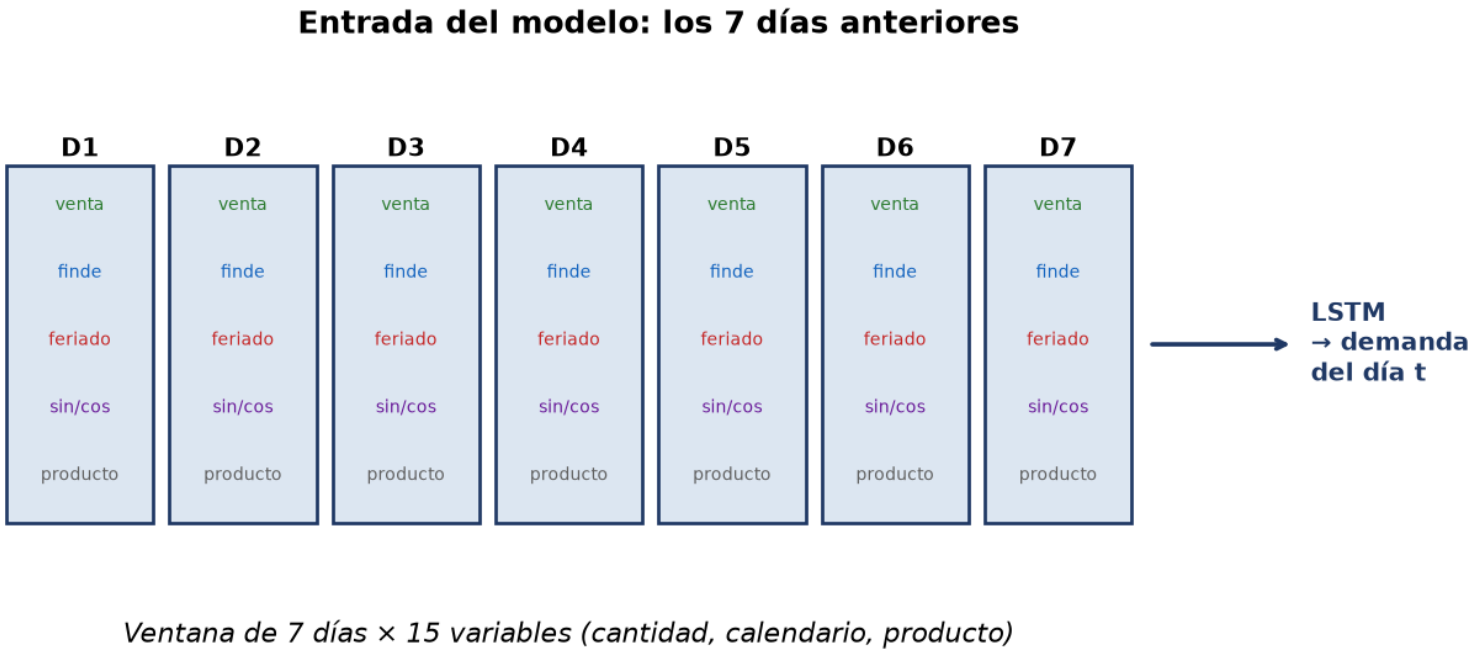
El patrón se repite cada semana: sábado pico (2.183) y miércoles valle (1.117).

FASE 1 · Variables creadas y secuencias

- Temporales: mes, día de la semana, semana del período.
- Indicadores: es_fin_de_semana (0/1) y es_feriado (0/1) con calendario real de Ecuador.
- Rezagos: ventas del día anterior, de hace 7 días y promedio móvil de 7 días.
- De negocio: categoría, unidad, stock_actual, dias_para_expirar.
- Secuencias: ventana de 7 días × 15 variables por producto (7 días → 1 día adelante).

Salida: datos/ventas_features.csv (600 filas × 22 columnas).

FASE 2 · Cómo modelamos

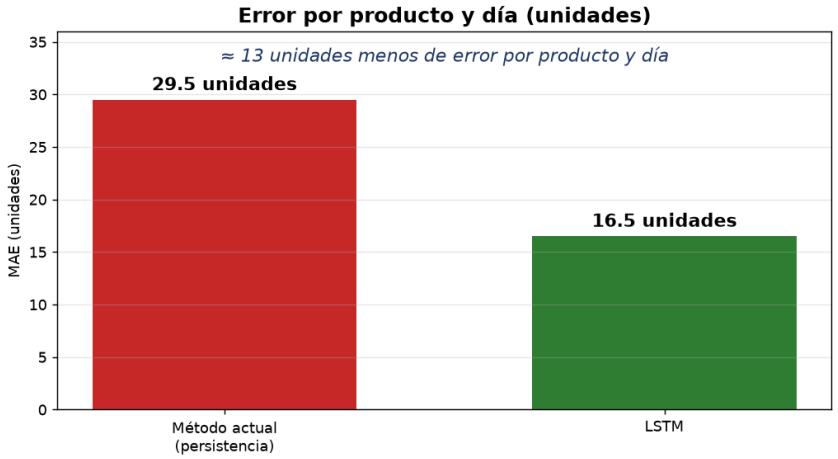


Ventana de 7 días × 15 variables (cantidad, calendario, producto)

Un solo modelo: red neuronal recurrente tipo LSTM (50 unidades + densa), como el cuaderno de referencia. Mirá los últimos 7 días y estima la venta del día siguiente.

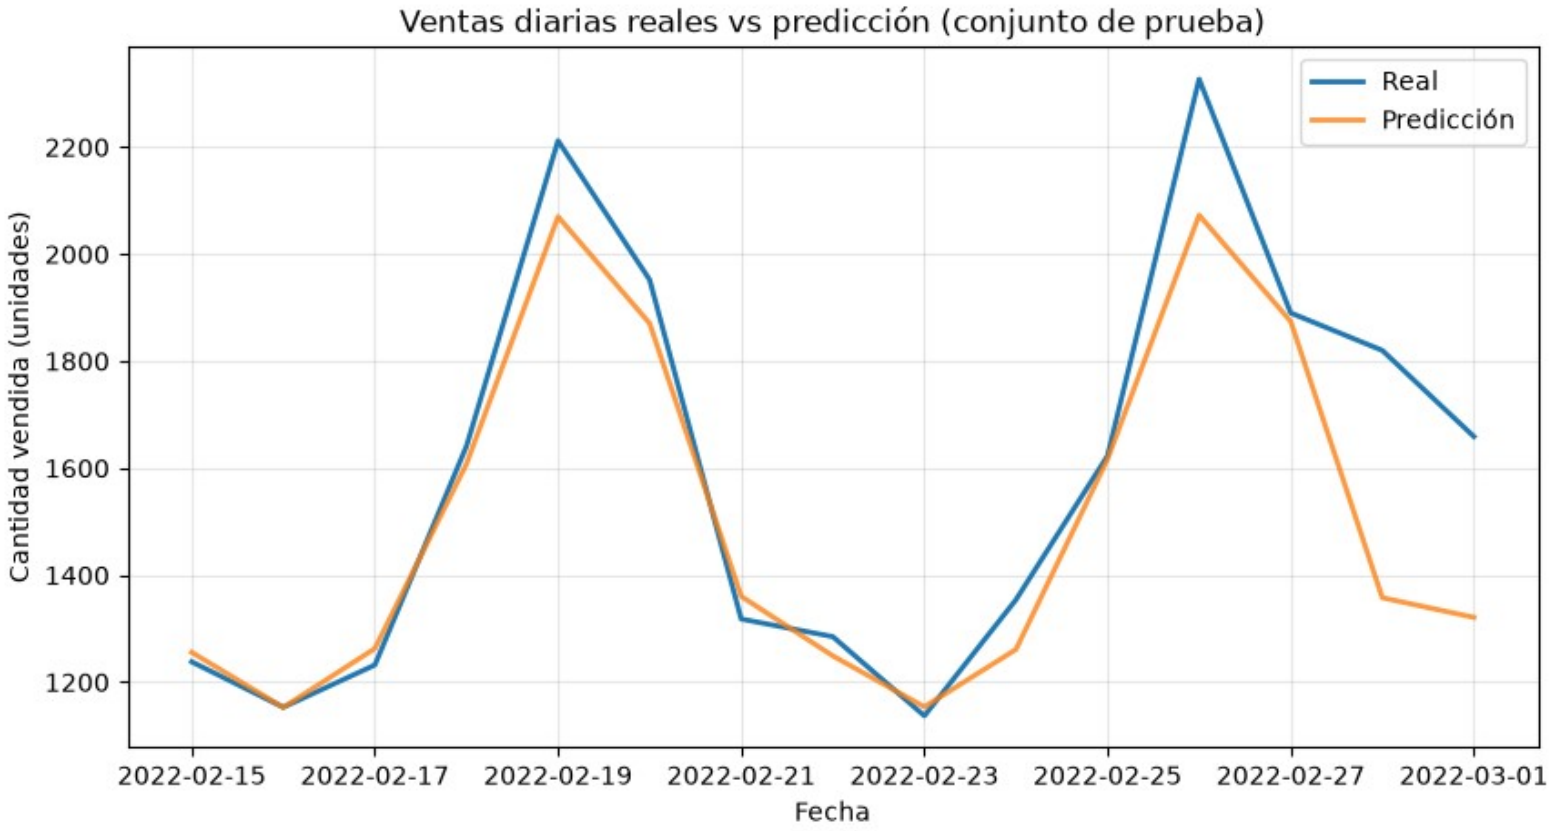
FASE 2 · Resultados (conjunto de prueba)

Método	RMSE	MAE	MAPE (%)
Método actual (persistencia)	44.12	32.43	19.54
Modelo RNN (LSTM)	24.28	17.97	10.88



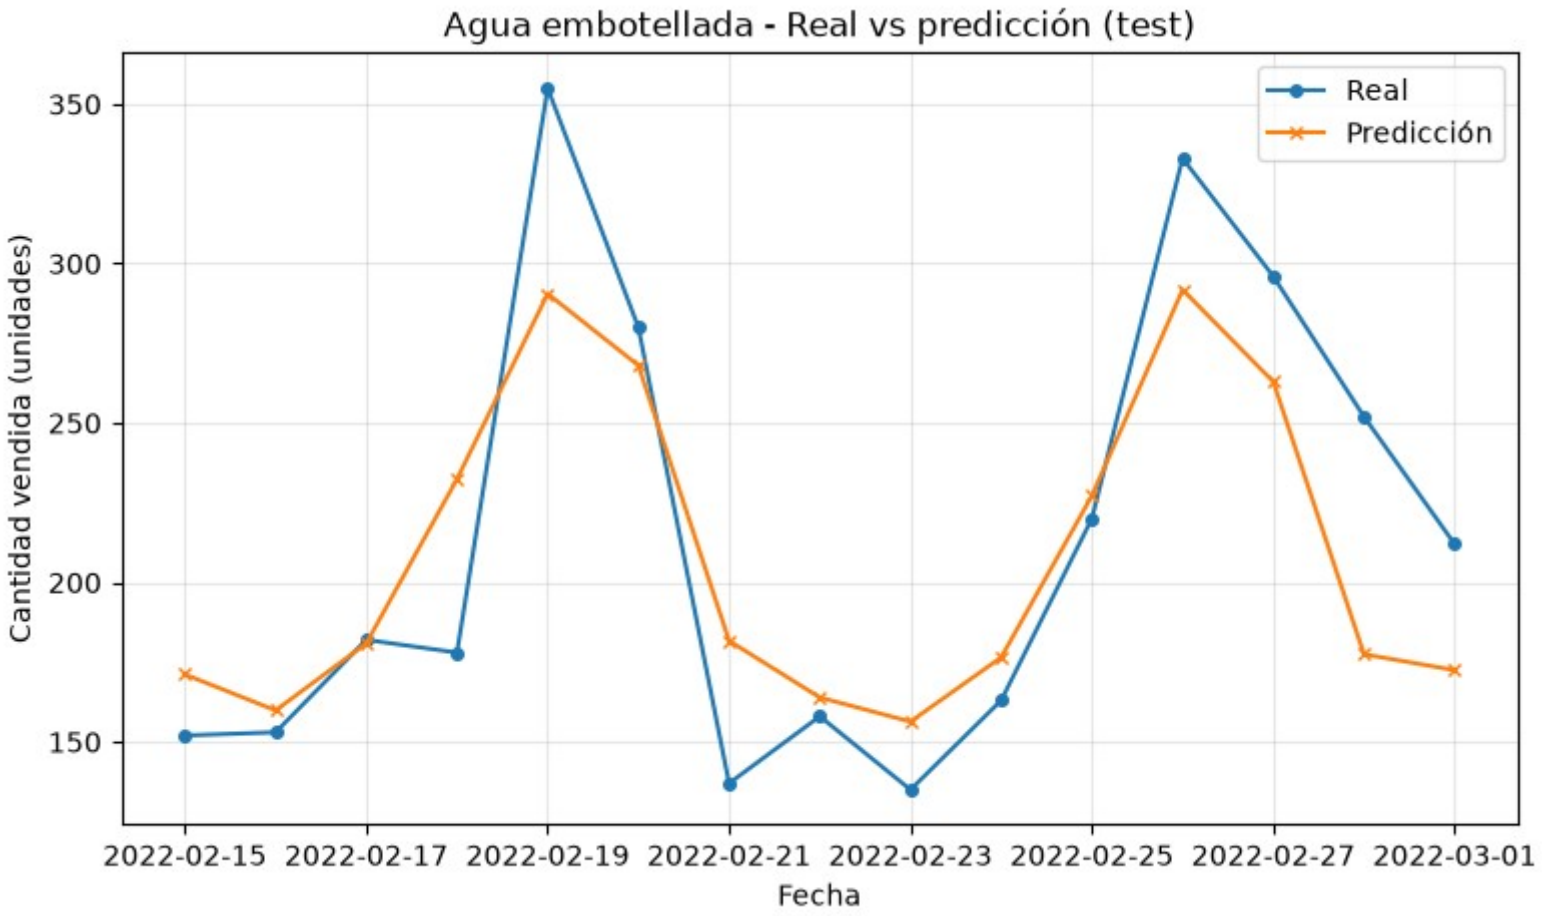
El modelo reduce el error un 45 % frente al método actual (RMSE). Un solo modelo RNN (LSTM), como el cuaderno de referencia.

FASE 2 · ¿Es confiable?



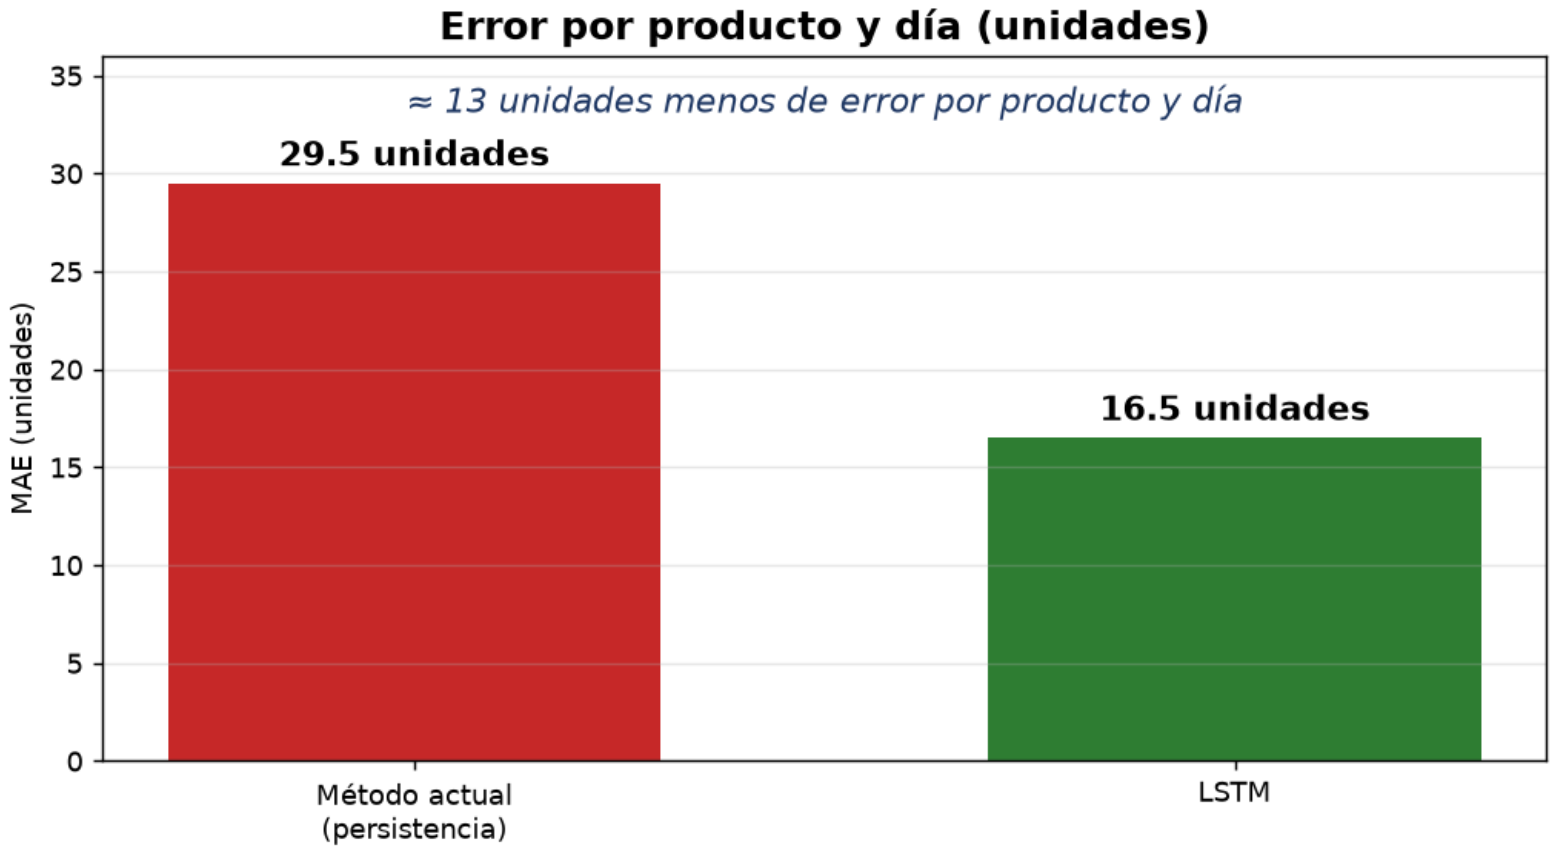
La predicción sigue la serie real, no solo el promedio. Split temporal sin fuga de información.

FASE 3 · Cómo se usa



predecir_venta(producto_id, fecha) -> float | predecir_batch(productos, fecha) -> list

Impacto de negocio



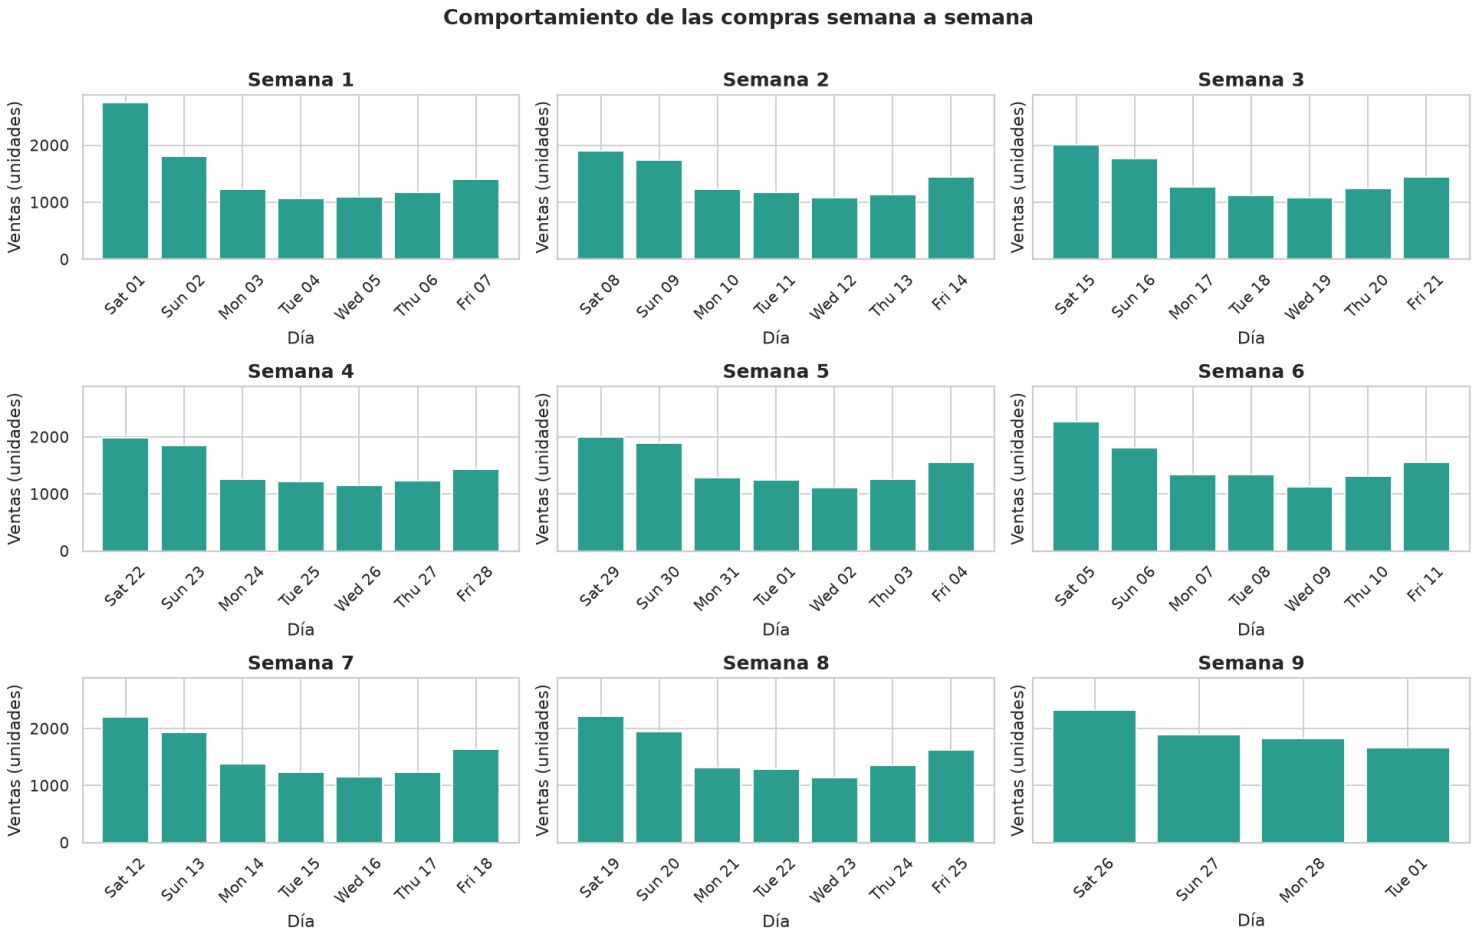
MAPE 10.9 % vs 19.5 %: ~130 unidades/día menos de error en el pedido (10 productos).

Roadmap y qué pedimos

- 1. Piloto de 4–6 semanas con tus datos reales para calibrar el modelo.
- 2. Integración con el punto de venta y la reposición.
- 3. Monitoreo del error y reentrenamiento periódico.
- Qué pedimos: aprobar el piloto y compartir el histórico de ventas.

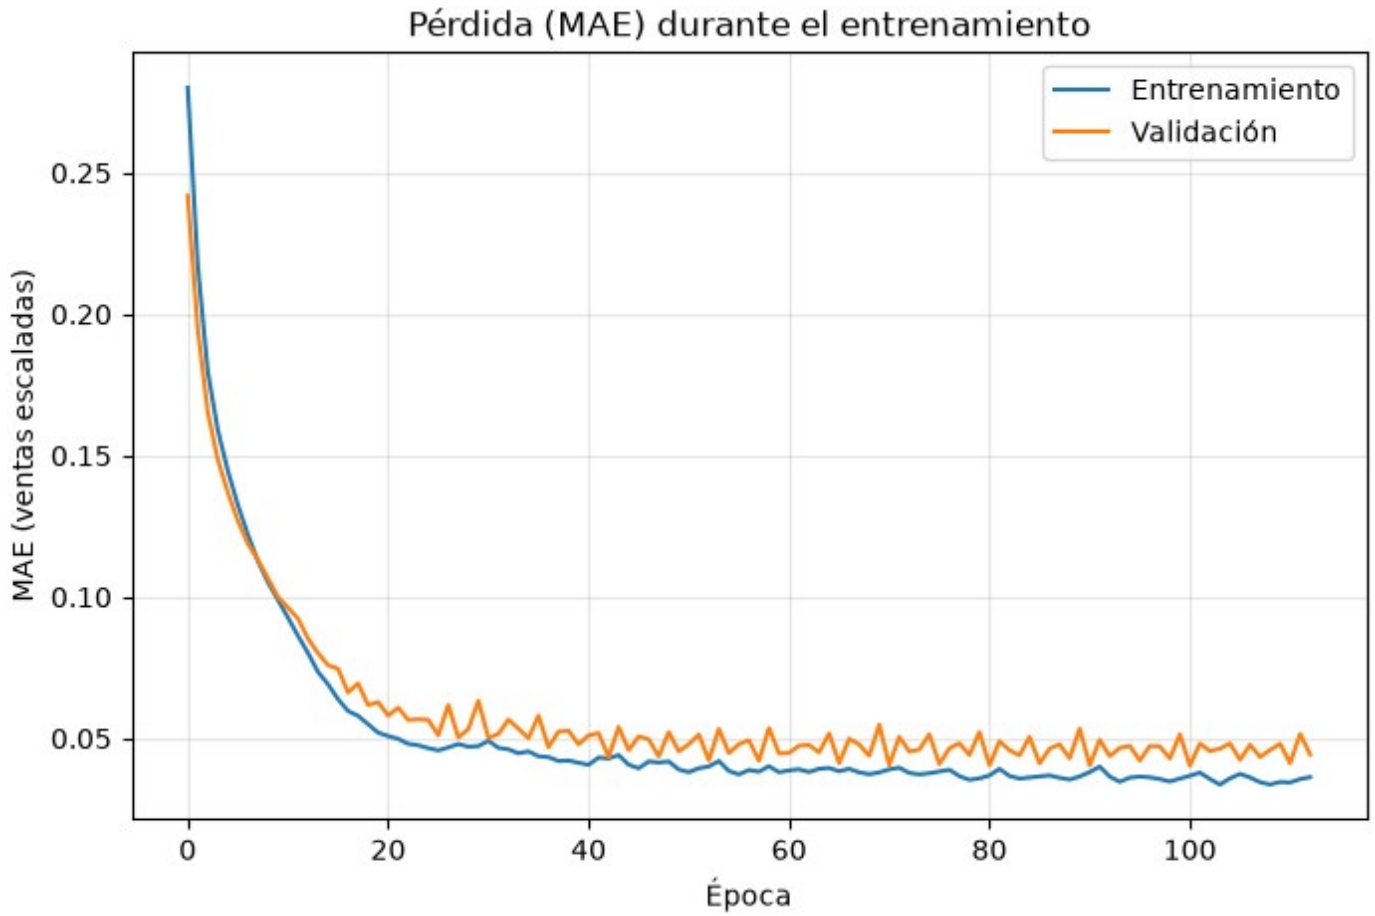
Honestidad: resultados sobre 60 días sintéticos y 150 predicciones de test. El enfoque está validado; falta calibrar con datos reales.

APÉNDICE · Ventas semana a semana



9 paneles, uno por semana. El patrón se repite cada semana (sábado pico, miércoles valle).

APÉNDICE · Convergencia



Pérdida de entrenamiento y validación por época (EarlyStopping, paciencia 12).

El modelo ya funciona

El siguiente paso es calibrarlo con tus datos reales. | *Preguntas*