Predicción de demanda para reducir quiebres de stock

Reporte para el cliente · Solución de predicción de demanda diaria

Preparado a partir del análisis de ventas de una tienda de barrio (10 productos, 60 días).

1. Resumen ejecutivo

Hoy la tienda repone 'a ojo': quiebres de stock en fin de semana y sobrestock entre semana. La demanda tiene un patrón claro que se puede predecir con un error del 10.9 %.

- El fin de semana vende un 55.6 % más que entre semana; los feriados, un 40.1 % más.
- El modelo reduce el error de pronóstico de 19.5 % a 10.9 % (un 45 % menos).
- Eso equivale a unas 130 unidades menos de error al día en la tienda (10 productos).
- El pipeline ya está listo: solo falta calibrarlo con los datos reales del negocio.

Pedido al cliente: aprobar un piloto de 4 a 6 semanas con datos reales y compartir el histórico de ventas.

2. El problema del negocio

En una tienda de barrio la reposición se hace por intuición. Cuando la demanda sube (fin de semana, feriados) hay quiebre de stock y se pierden ventas; cuando baja, hay capital inmovilizado en inventario. La pregunta que el modelo responde es simple: ¿cuánto venderé mañana de cada producto?

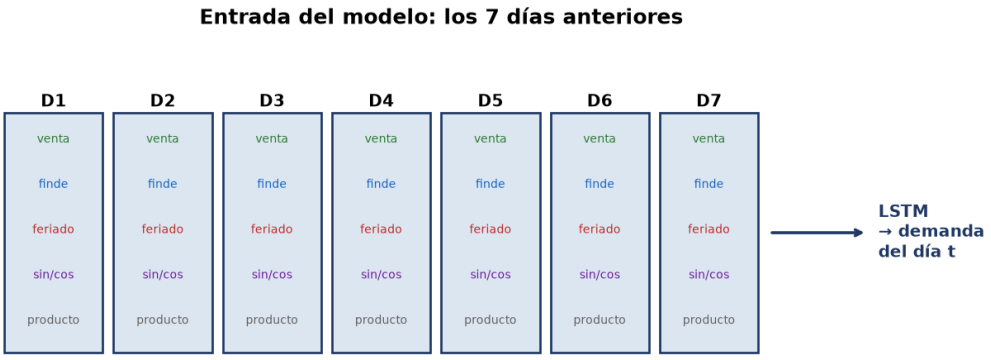
- Quiebres de stock en los días de mayor flujo (fines de semana y feriados).
- Sobrestock en los días de menor flujo (miércoles, días normales).
- Sin una previsión, el pedido se dimensiona por promedio, que falla todos los fines de semana.

3. La solución

Construimos un modelo que estima la demanda diaria por producto usando el historial de ventas y el calendario. El modelo mira los últimos 7 días de cada producto y el calendario, y estima la venta del día siguiente.

- Un solo modelo aprende los 10 productos (identifica cuál por su código).

- Usa las variables que importan en este negocio: fin de semana, feriados y memoria de ventas recientes.
- Se entrega listo para integrar: recibe un producto (o un lote) y una fecha, y devuelve la predicción.



Ventana de 7 días × 15 variables (cantidad, calendario, producto)

4. Los datos

El dataset de partida es público, de Kaggle: Retail Store Inventory Forecasting Dataset.

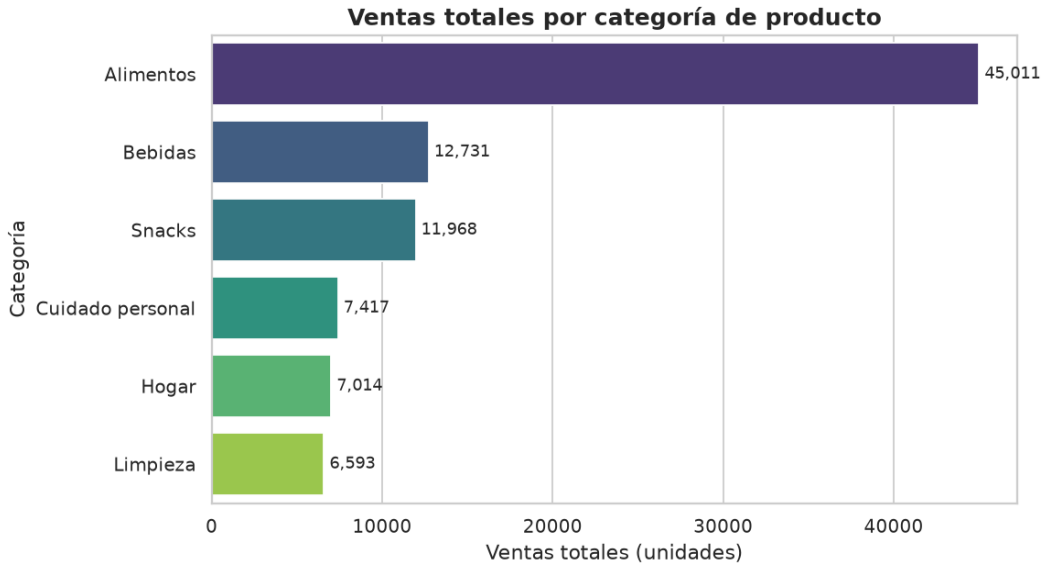
- URL de origen: https://www.kaggle.com/datasets/anirudhchauhan/retail-store-inventory-forecasting-dataset
- Tipo: el dataset base es público; el dataset analizado fue construido a partir de él.
- Dataset construido: 10 productos reales × 60 días (1 ene – 1 mar 2022) = 600 registros.

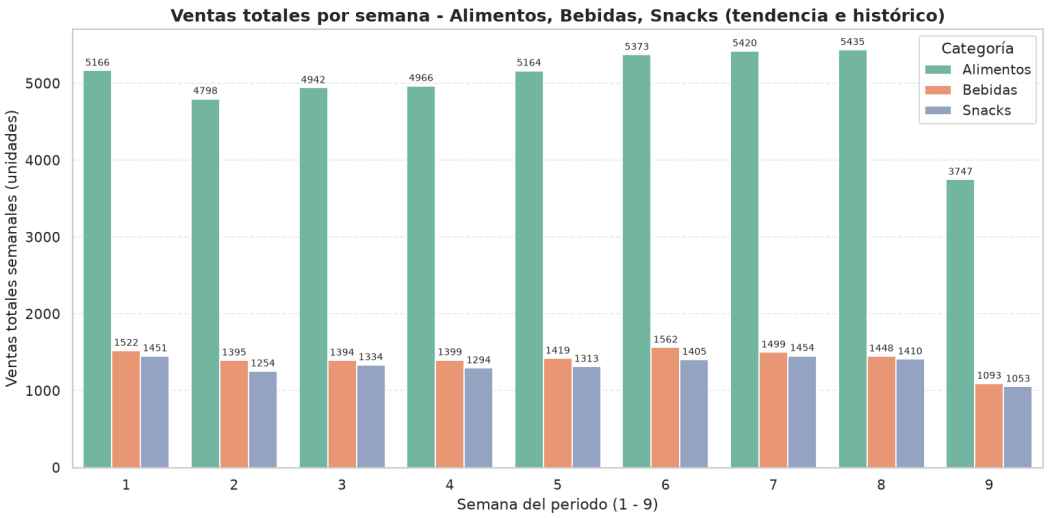
Modificaciones realizadas al dataset original:

Aspecto	Dataset original	Dataset construido
Idioma y nombres	Columnas en inglés genérico	Traducido al español; 10 productos reales con categoría y unidad.
Selección de productos	20 product_id sin categoría consistente	10 productos, cada uno con categoría y unidad correctas.
Período	731 días (2022–2024)	60 días (1 ene – 1 mar 2022) para el análisis semana a semana.
Patrón de compras	Datos aleatorios (Holiday/Promotion no influye: 136.5 vs 136.4)	Estacionalidad semanal, impulso en feriados de Ecuador y tendencia leve.
Estructura de archivos	Un único archivo ancho	Separado en catálogo (inventory.csv) e historial de ventas (sales_history.csv).

Categorías y productos analizados:

Categoría	Ventas totales	Participación	Prom. diario	Productos
Alimentos	45011	49.6 %	150.0	Arroz, Leche, Pan, Aceite, Huevos
Bebidas	12731	14.0 %	212.2	Agua embotellada
Snacks	11968	13.2 %	199.5	Galletas
Cuidado personal	7417	8.2 %	123.6	Jabón de baño
Hogar	7014	7.7 %	116.9	Papel higiénico
Limpieza	6593	7.3 %	109.9	Detergente en polvo

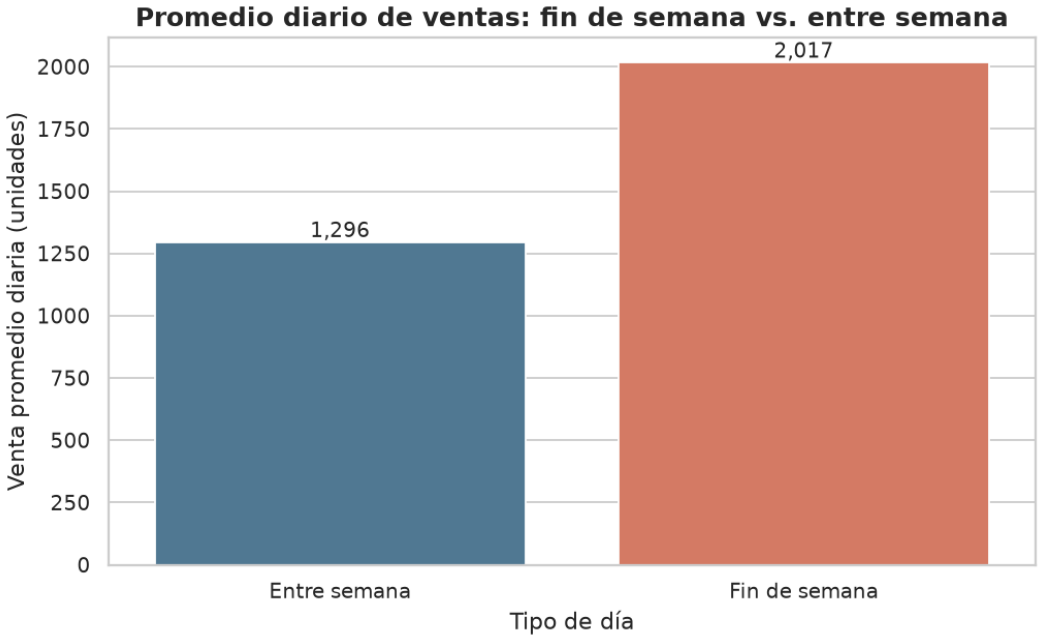


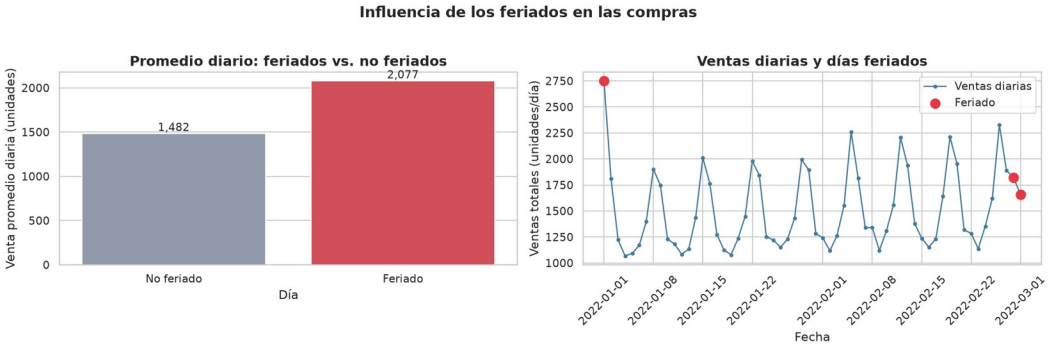


5. Lo que encontramos en los datos

El comportamiento de las compras muestra un patrón semanal claro y recurrente.

- Sábado: 2.183 unidades/día (pico). Miércoles: 1.117 unidades/día (valle).
- Fin de semana vende un 55.6 % más que entre semana (2.016,7 vs 1.296,0).
- Feriados venden un 40.1 % más (2.077,3 vs 1.482,5). Feriados usados: 1 ene, 28 feb y 1 mar (Ecuador).
- 1 de enero (sábado + Año Nuevo) fue el pico más alto del período: 2.753 unidades.
- Alimentos concentra el 49.6 % de las ventas, pero Bebidas y Snacks son los más rotativos por producto (212 y 199 unidades/día).





6. Las variables que creamos

A partir de la fecha y del negocio creamos variables que el modelo necesita:

Variable	Para qué sirve (negocio)
es_fin_de_semana	1 si es sábado o domingo. Efecto confirmado: +55.6 %.
es_feriado	1 si es feriado nacional de Ecuador. Efecto confirmado: +40.1 %.
tipo_dia	Clasificación en 4 niveles (sin pérdida de información).
dia_semana / mes	Componentes de la fecha para capturar el ciclo semanal y mensual.
semana_del_periodo	Semana dentro del período (1..9) para el análisis semana a semana.
ventas_dia_anterior	Ventas del día anterior por producto (memoria inmediata).
ventas_hace_7_dias	Ventas del mismo día de la semana anterior (estacionalidad).
promedio_movil_7d	Promedio de los 7 días previos por producto (tendencia local).

dias_para_expirar	Días entre la venta y la expiración del producto.

La justificación de cada variable viene del negocio: en una tienda de barrio el flujo se concentra en fin de semana y feriados, por eso esos indicadores son obligatorios. Los rezagos dan memoria al modelo para que aprenda de la historia reciente.

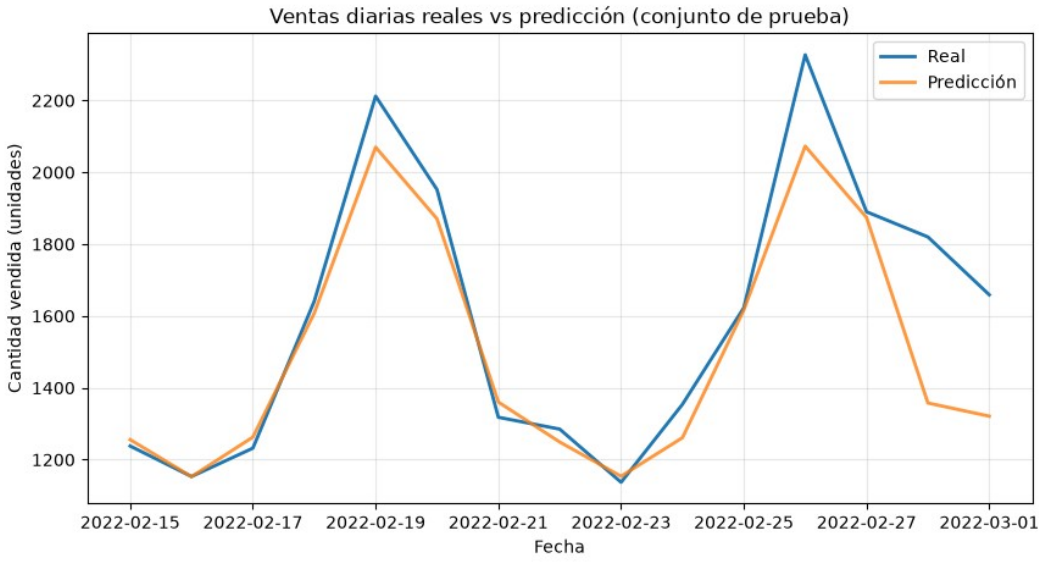
7. Resultados del modelo

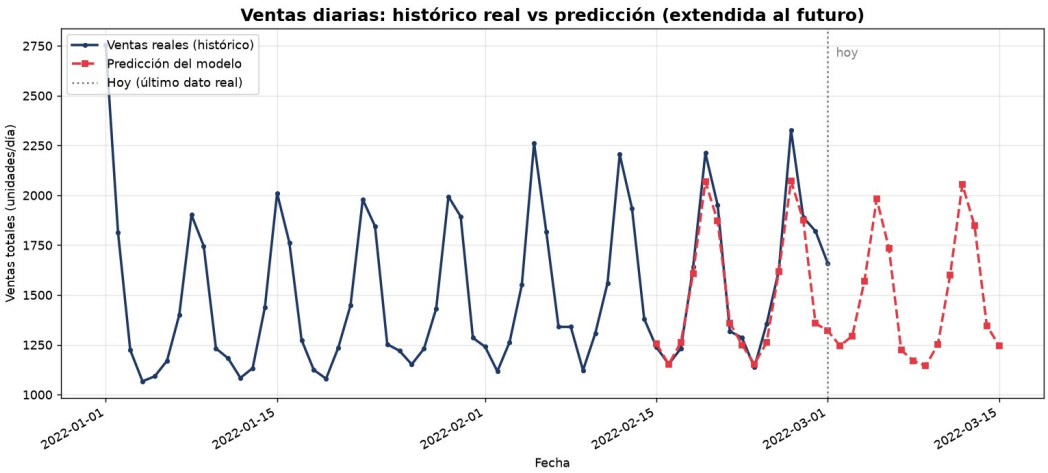
El modelo predice la demanda diaria por producto con un error del 10.9 %, frente al 19.5 % del método actual (repetir la venta de ayer).

Método	Error RMSE	Error MAE	Error MAPE (%)
Método actual (repetir venta de ayer)	44.12	32.43	19.54
Modelo predictivo	24.28	17.97	10.88

El modelo reduce el error un 45 %.

- División temporal: 75 % train / 25 % test (últimos 15 días). Nunca aleatoria.
- El escalado se ajusta solo con train: sin fuga de información.
- El baseline de persistencia es la referencia obligatoria del forecasting.
- Test: 150 predicciones (15 días × 10 productos).



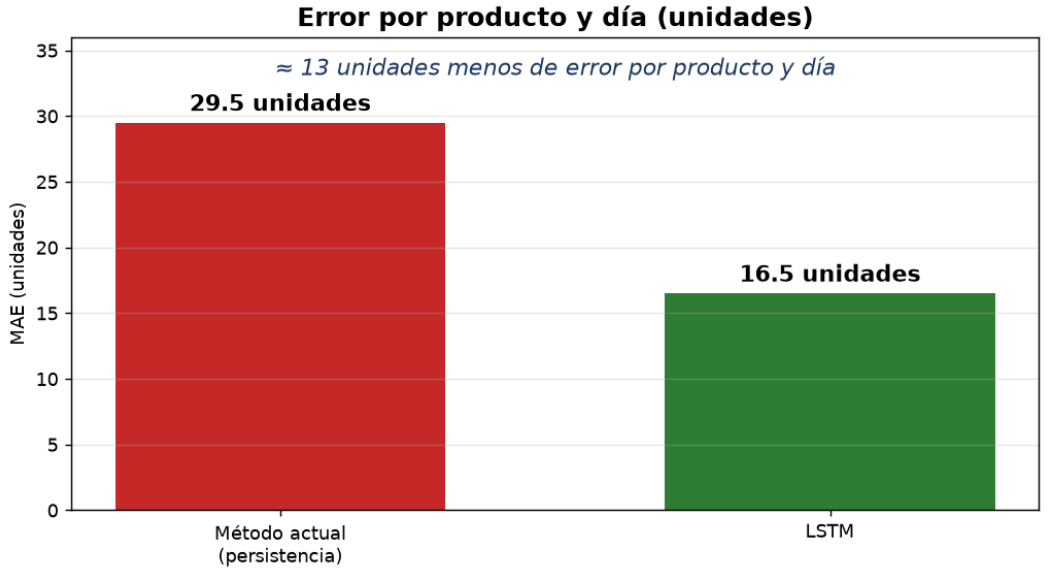


La gráfica muestra las ventas reales (línea sólida) y las predicciones del modelo (línea discontinua). Las predicciones se extienden más allá de los valores reales, mostrando la proyección del modelo para los próximos días.

8. Impacto para el negocio

Traducir el error a unidades permite dimensionar el pedido con más precisión.

- Venta media por producto y día: 151 unidades.
- Error por producto y día: 16 unidades (modelo) vs 29 (método actual).
- En la tienda completa: unas 130 unidades diarias menos de error en el pedido.
- Beneficio esperado: menos quiebres de stock en fin de semana y feriados, y menos capital inmovilizado entre semana.



Nota: la traducción a dinero es ilustrativa (supuesto de precio promedio por unidad). Se valida con los precios reales del cliente.

9. Anexo: transparencia y metodología

Cómo se construyó (en lenguaje simple):

- Se partió de un dataset público (Kaggle) y se construyó uno propio de 10 productos × 60 días.
- Se verificó la calidad: sin nulos, sin duplicados, sin valores negativos, 60 días de cobertura.
- Se crearon variables de calendario (fin de semana, feriados) y memoria (ventas de días anteriores).
- Se entrenó un modelo de red neuronal recurrente que mira los últimos 7 días y estima la venta del día siguiente.
- Se comparó contra el método actual (repetir la venta de ayer): el modelo reduce el error un 45 %.

Limitaciones (para tomar decisiones con criterio):

- Dataset sintético de 60 días; solo 150 predicciones de test.
- Solo 3 días feriado en la ventana: la estimación del efecto feriado es preliminar.
- El modelo necesita los 7 días previos reales para predecir.
- Sin datos reales, el error real del negocio puede diferir.

Métricas usadas: RMSE (penaliza errores grandes), MAE (error medio en unidades), MAPE (error porcentual, permite comparar entre productos).