Tarea 01 — Ingeniería de características

Reporte de análisis exploratorio y variables creadas

1. Dataset

El dataset identificado es el «Retail Store Inventory Forecasting Dataset», publicado de forma pública en Kaggle. A partir de él se construyó un dataset propio (en español) para la tarea.

- Origen del dataset base: https://www.kaggle.com/datasets/anirudhchauhan/retail-store-inventory-forecasting-dataset
- Tipo: público (Kaggle) — el dataset analizado es construido a partir de él.
- Dataset base: 73,100 filas, 15 columnas, 5 tiendas y 20 productos (2022-2024).

Modificaciones realizadas al dataset original:

Aspecto	Dataset original	Dataset construido
Idioma y nombres	Columnas y categorías en inglés genérico	Se tradujo al español y se asignaron 10 productos reales de tienda de barrio.
Selección de productos	20 product_id sin categoría asociada de forma consistente	10 productos, cada uno con su categoría y unidad correctas.
Período	731 días (2022-2024)	60 días (2022-01-01 a 2022-03-01) para el análisis semana a semana.
Patrón de compras	Datos aleatorios sin estacionalidad ni efecto feriados	Se incorporó estacionalidad semanal, impulso en feriados de Ecuador y tendencia.
Estructura de archivos	Un único archivo ancho	Se separó en `inventory.csv` (catálogo) y `sales_history.csv` (ventas).

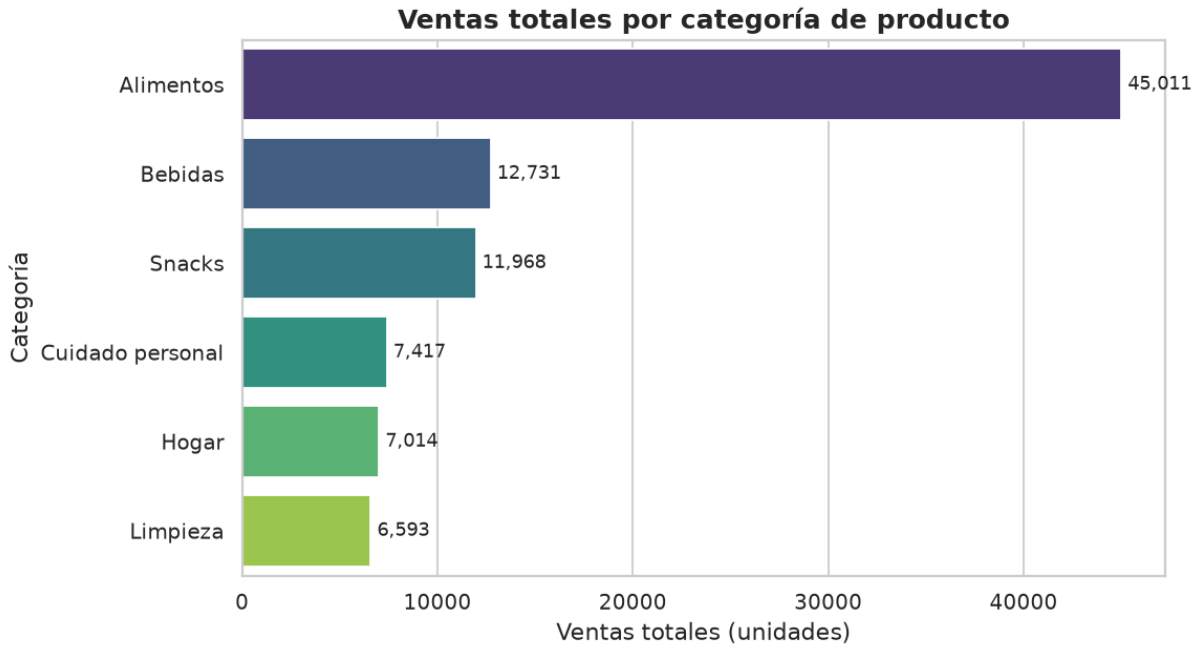
Calidad de los datos construidos:

Chequeo	Resultado	Detalle
Columnas ventas	OK	Todas presentes
Columnas inventario	OK	Todas presentes
Valores nulos	OK	0 celdas nulas en total
Duplicados (producto, fecha)	OK	0 duplicados
Productos en inventario sin ventas	OK	ninguno
Cobertura temporal	OK	60 días (2022-01-01 a 2022-

		03-01)
Valores negativos (ventas/stock)	OK	0 negativos

2. Análisis exploratorio y visualizaciones

Categorías de productos más importantes. Las categorías se ordenan por ventas totales del período; Alimentos concentra la mayor parte de las ventas.



Resumen por categoría:

categoria	ventas_totales	venta_promedio	num_productos	participacion_%
Alimentos	45011	150.04	5	49.6
Bebidas	12731	212.18	1	14.0
Snacks	11968	199.47	1	13.2
Cuidado personal	7417	123.62	1	8.2
Hogar	7014	116.9	1	7.7
Limpieza	6593	109.88	1	7.3

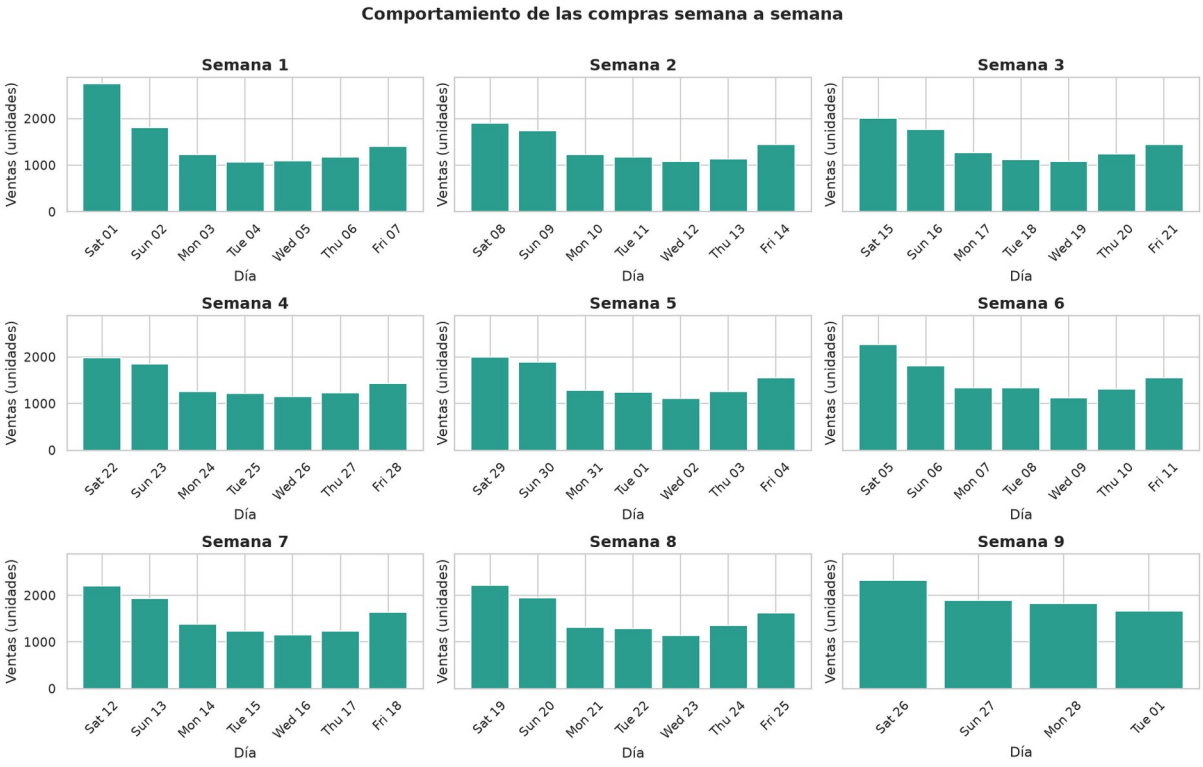
Productos analizados:

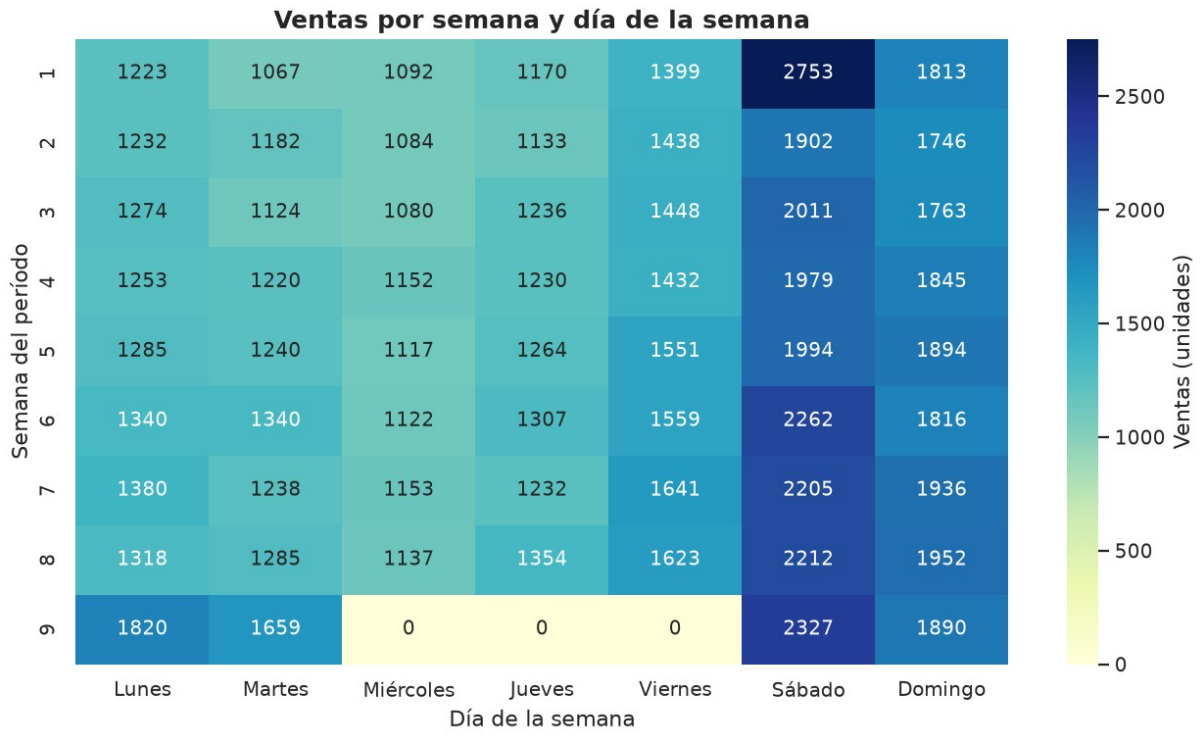
product_id	nombre	ventas_totales	venta_promedio	venta_maxima
P0008	Agua embotellada	12731	212.18	394
P0009	Galletas	11968	199.47	411

P0005	Huevos	11085	184.75	389
P0003	Pan de molde	10357	172.62	323
P0002	Leche entera	9015	150.25	264
P0001	Arroz blanco	8282	138.03	233
P0007	Jabón de baño	7417	123.62	179
P0010	Papel higiénico	7014	116.9	211
P0006	Detergente en polvo	6593	109.88	233
P0004	Aceite vegetal	6272	104.53	143

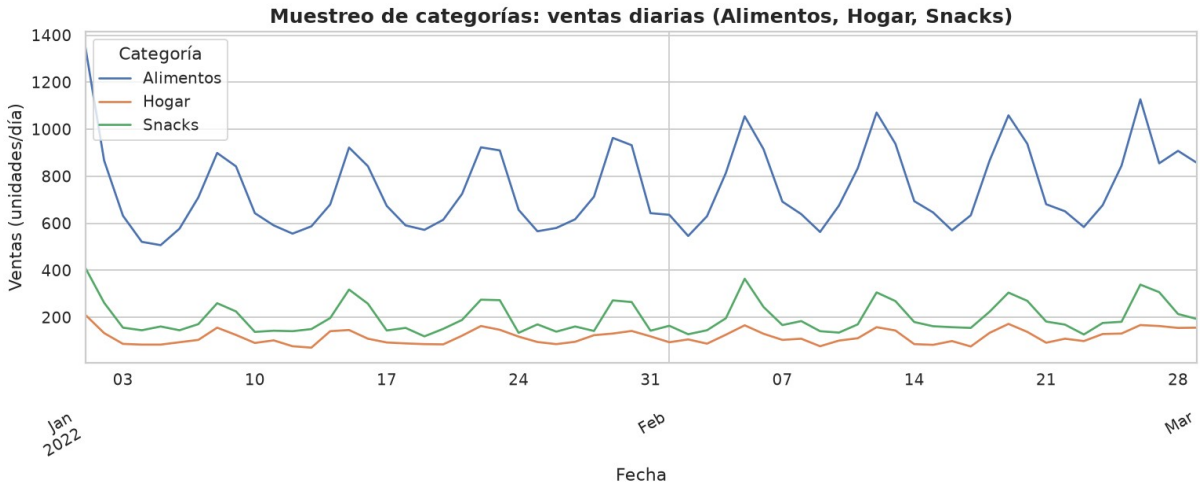
Comportamiento de las compras a lo largo del tiempo, organizado semana a semana durante los dos meses del período. Cada panel resume una semana y permite observar los cambios día a día y el patrón recurrente de fin de semana.







Muestreo de categorías de productos para facilitar la visualización del comportamiento conjunto a lo largo del tiempo.

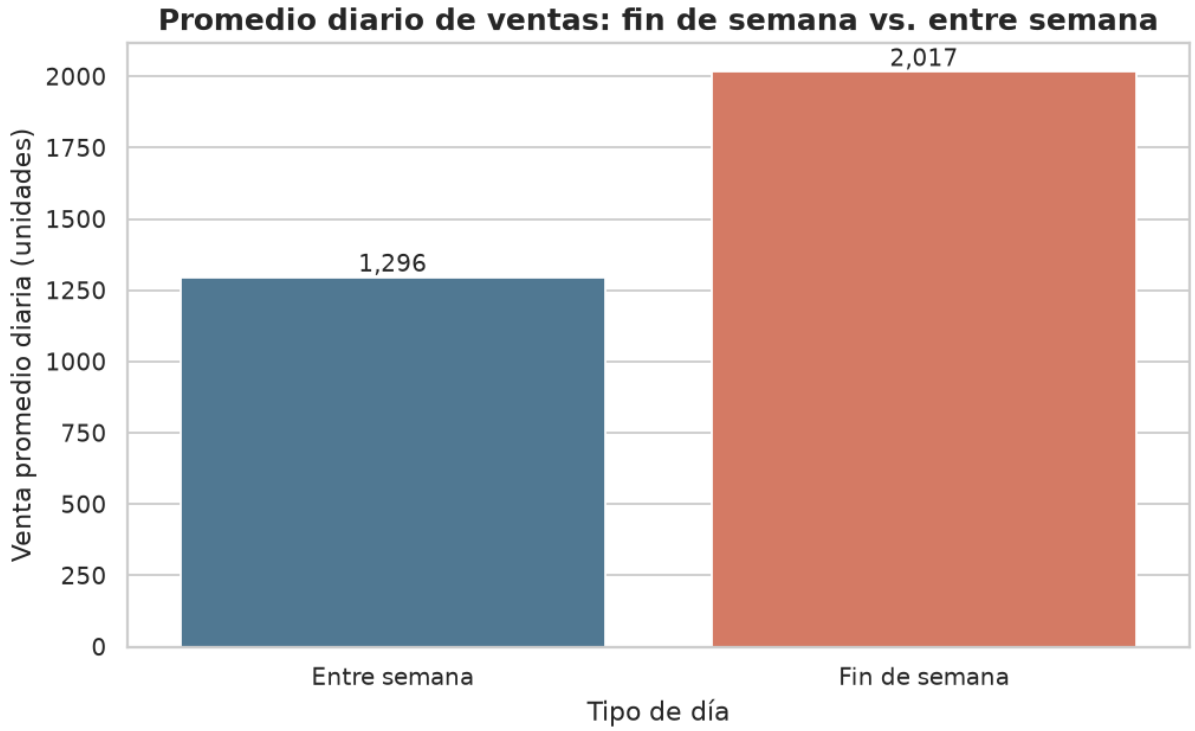


3. Variables creadas

Durante la ingeniería de características se crearon las siguientes variables temporales y de rezago:

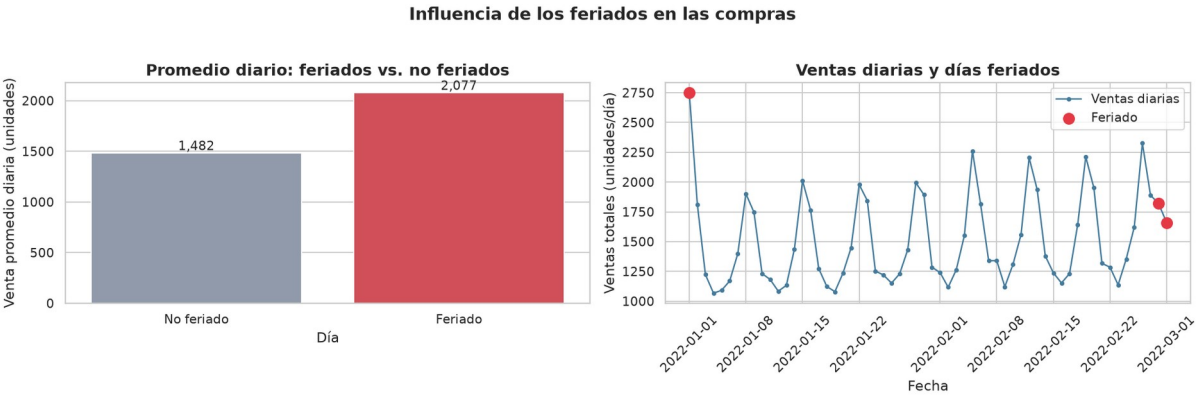
Variable	Tipo	Descripción
dia_semana / nombre_dia	Numérica / texto	Día de la semana (0=Lunes … 6=Domingo).
mes / dia_del_mes / anio	Numérica	Componentes de la fecha para capturar estacionalidad.
semana_iso / semana_del_periodo	Numérica	Semana del año y semana dentro del período (1..N).
es_fin_de_semana	Indicador (0/1)	1 si la venta es sábado o domingo; 0 en caso contrario.
es_feriado	Indicador (0/1)	1 si la fecha es feriado nacional de Ecuador; 0 si no.
tipo_dia	Categórica (4 niveles)	Entre semana / Fin de semana / Feriado / Feriado (fin de semana). Sin pérdida: biyectiva con (`es_fin_de_semana`, `es_feriado`).
ventas_dia_anterior / lag_7	Numérica	Ventas del día anterior y de la semana anterior por producto.
promedio_movil_7d	Numérica	Promedio móvil de 7 días de las ventas por producto.
dias_para_expirar	Numérica	Días entre la venta y la fecha de expiración del producto.

Efecto del fin de semana. El promedio diario de ventas es claramente mayor los sábados y domingos, lo que confirma el patrón semanal de compras.



tipo_dia	venta_promedio_diaria	dias	ventas_totales
Entre semana	1296.0	42	54434
Fin de semana	2016.7	18	36300

Efecto de los feriados. Se comparan los días feriados con los días normales y se señalan los feriados sobre la serie temporal.



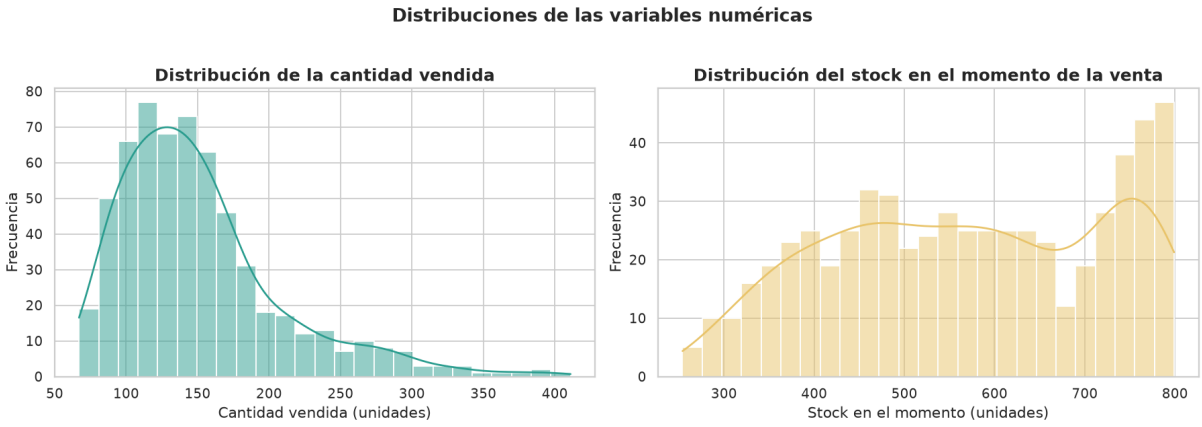
Feriados presentes en el período (Ecuador):

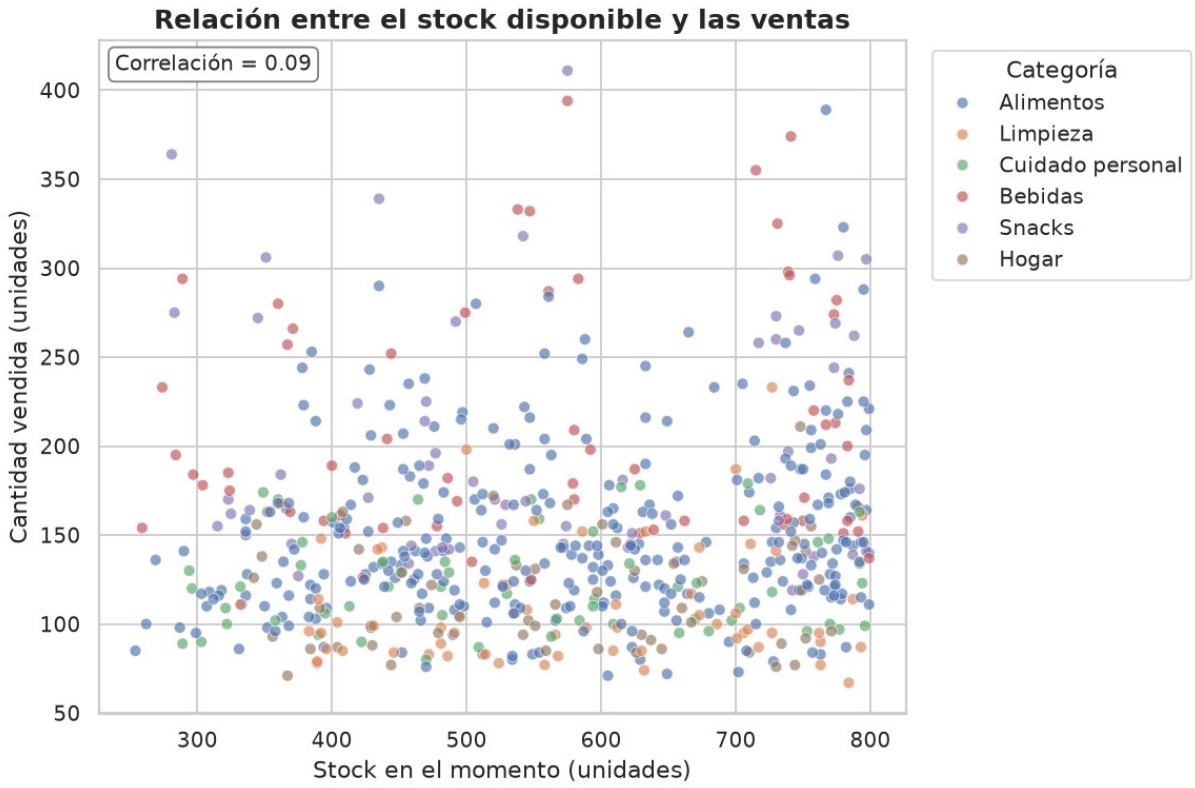
fecha	dia	feriado

2022-01-01	Sábado	New Year's Day	
2022-02-28	Lunes	Carnival	
2022-03-01	Martes	Carnival	

feriado	venta_promedio_diaria	dias	ventas_totales
No feriado	1482.5	57	84502
Feriado	2077.3	3	6232

Variables numéricas y relación stock–ventas:





4. Criterios del análisis y conclusiones

- Las figuras muestran patrones reconocibles: pico de ventas en fin de semana y en feriados, y una tendencia creciente leve durante el período.
- Cada figura incluye título y nombres en los ejes X e Y para su correcta interpretación.
- El negocio (tienda de barrio) explica la relevancia de las variables: fines de semana y feriados concentran más compras, por lo que el inventario debe reforzarse esos días.
- Las variables creadas permiten modelar la demanda futura respetando el calendario real.