# Tarea 01 — Ingeniería de características

*Reporte de análisis exploratorio y variables creadas*

## 1. Dataset

El dataset identificado es el «Retail Store Inventory Forecasting Dataset», publicado de forma pública en Kaggle. A partir de él se construyó un dataset propio (en español) para la tarea.

- Origen del dataset base: https://www.kaggle.com/datasets/anirudhchauhan/retail-store-inventory-forecasting-dataset
- Tipo: público (Kaggle) — el dataset analizado es construido a partir de él.
- Dataset base: 73,100 filas, 15 columnas, 5 tiendas y 20 productos (2022-2024).

**Modificaciones realizadas al dataset original:**

| Aspecto | Dataset original | Dataset construido |
|---|---|---|
| **Idioma y nombres** | Columnas y categorías en inglés genérico | Se tradujo al español y se asignaron 10 productos reales de tienda de barrio. |
| **Selección de productos** | 20 product_id sin categoría asociada de forma consistente | 10 productos, cada uno con su categoría y unidad correctas. |
| **Período** | 731 días (2022-2024) | 60 días (2022-01-01 a 2022-03-01) para el análisis semana a semana. |
| **Patrón de compras** | Datos aleatorios sin estacionalidad ni efecto feriados | Se incorporó estacionalidad semanal, impulso en feriados de Ecuador y tendencia. |
| **Estructura de archivos** | Un único archivo ancho | Se separó en `inventory.csv` (catálogo) y `sales_history.csv` (ventas). |

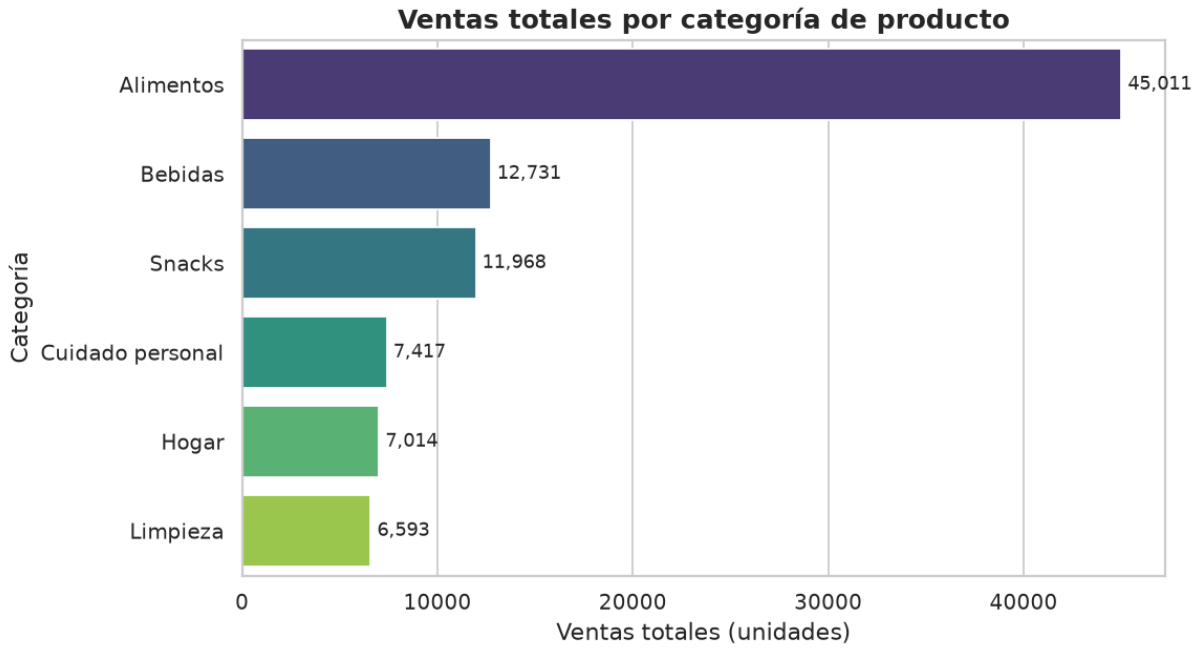
**Calidad de los datos construidos:**

| Chequeo | Resultado | Detalle |
|---|---|---|
| **Columnas ventas** | OK | Todas presentes |
| **Columnas inventario** | OK | Todas presentes |
| **Valores nulos** | OK | 0 celdas nulas en total |
| **Duplicados (producto, fecha)** | OK | 0 duplicados |
| **Productos en inventario sin ventas** | OK | ninguno |
| **Cobertura temporal** | OK | 60 días (2022-01-01 a 2022- |

| | | |
|---|---|---|
| | | 03-01) |
| **Valores negativos (ventas/stock)** | OK | 0 negativos |

## 2. Análisis exploratorio y visualizaciones

Categorías de productos más importantes. Las categorías se ordenan por ventas totales del período; Alimentos concentra la mayor parte de las ventas.




**Resumen por categoría:**

| categoria | ventas_totales | venta_promedio | num_productos | participacion_% |
|---|---|---|---|---|
| **Alimentos** | 45011 | 150.04 | 5 | 49.6 |
| **Bebidas** | 12731 | 212.18 | 1 | 14.0 |
| **Snacks** | 11968 | 199.47 | 1 | 13.2 |
| **Cuidado personal** | 7417 | 123.62 | 1 | 8.2 |
| **Hogar** | 7014 | 116.9 | 1 | 7.7 |
| **Limpieza** | 6593 | 109.88 | 1 | 7.3 |

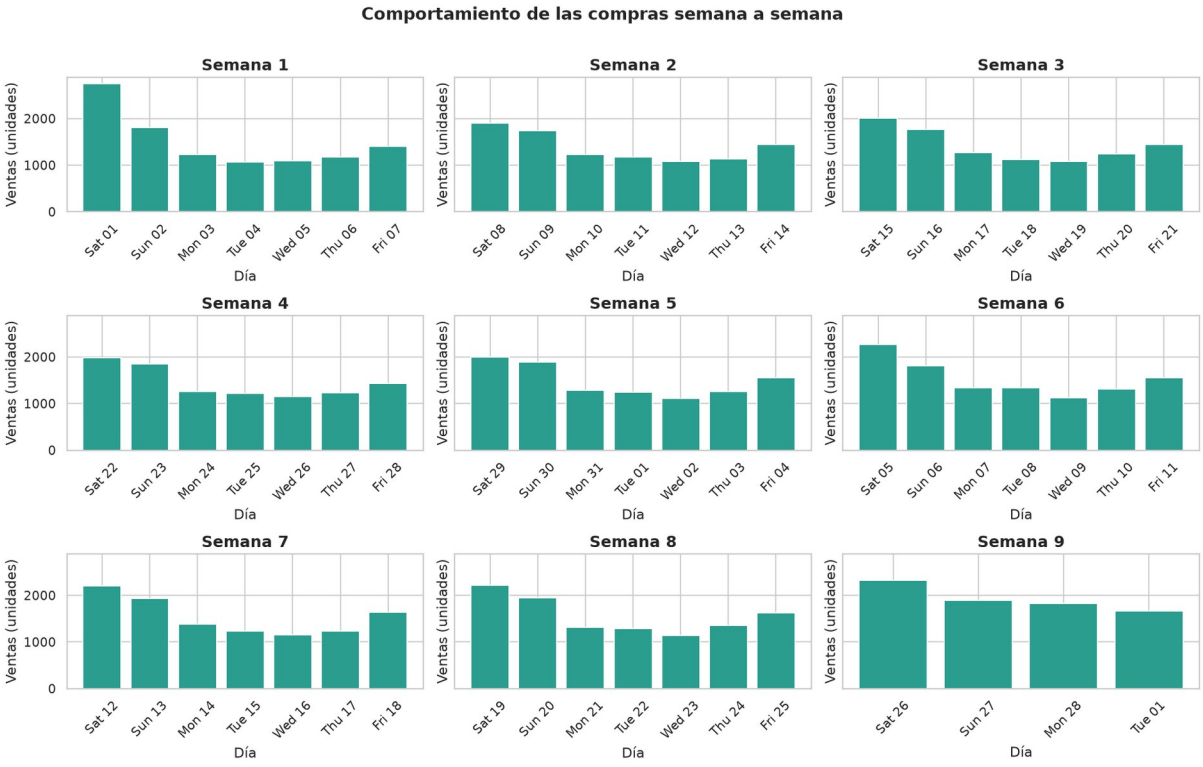
**Productos analizados:**

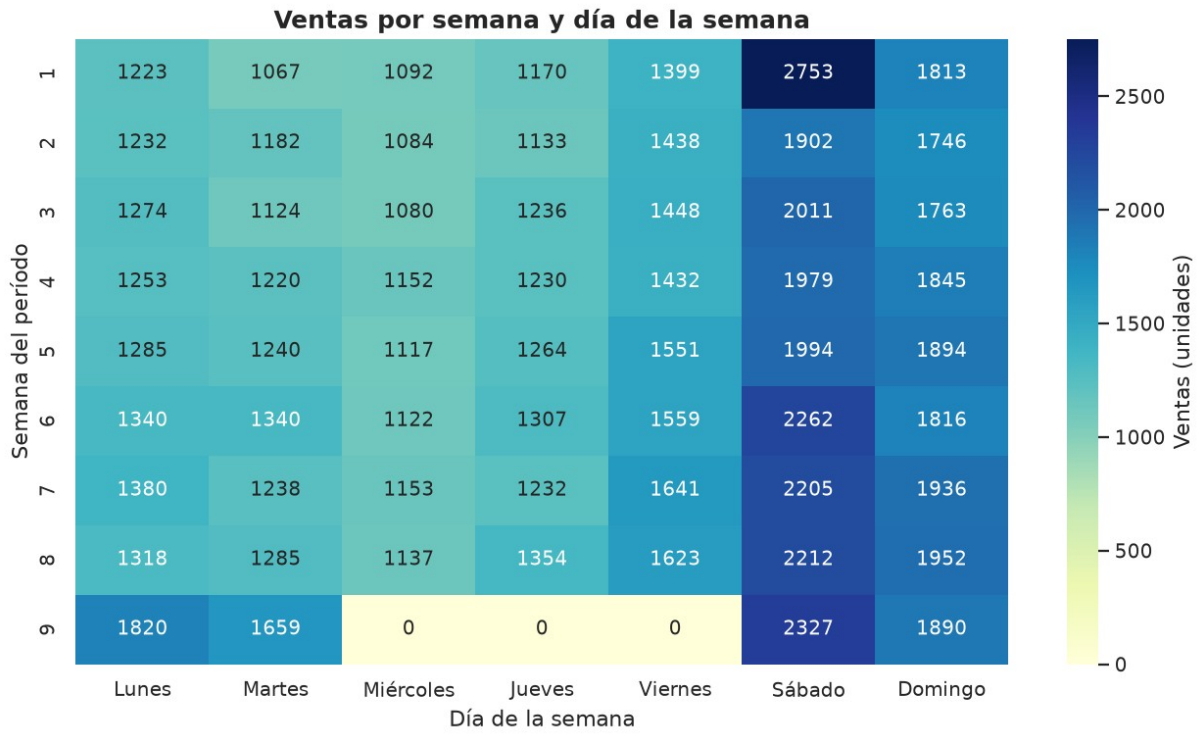
| product_id | nombre | ventas_totales | venta_promedio | venta_maxima |
|---|---|---|---|---|
| **P0008** | Agua embotellada | 12731 | 212.18 | 394 |
| **P0009** | Galletas | 11968 | 199.47 | 411 |

| | | | | |
|---|---|---|---|---|
| **P0005** | Huevos | 11085 | 184.75 | 389 |
| **P0003** | Pan de molde | 10357 | 172.62 | 323 |
| **P0002** | Leche entera | 9015 | 150.25 | 264 |
| **P0001** | Arroz blanco | 8282 | 138.03 | 233 |
| **P0007** | Jabón de baño | 7417 | 123.62 | 179 |
| **P0010** | Papel higiénico | 7014 | 116.9 | 211 |
| **P0006** | Detergente en polvo | 6593 | 109.88 | 233 |
| **P0004** | Aceite vegetal | 6272 | 104.53 | 143 |

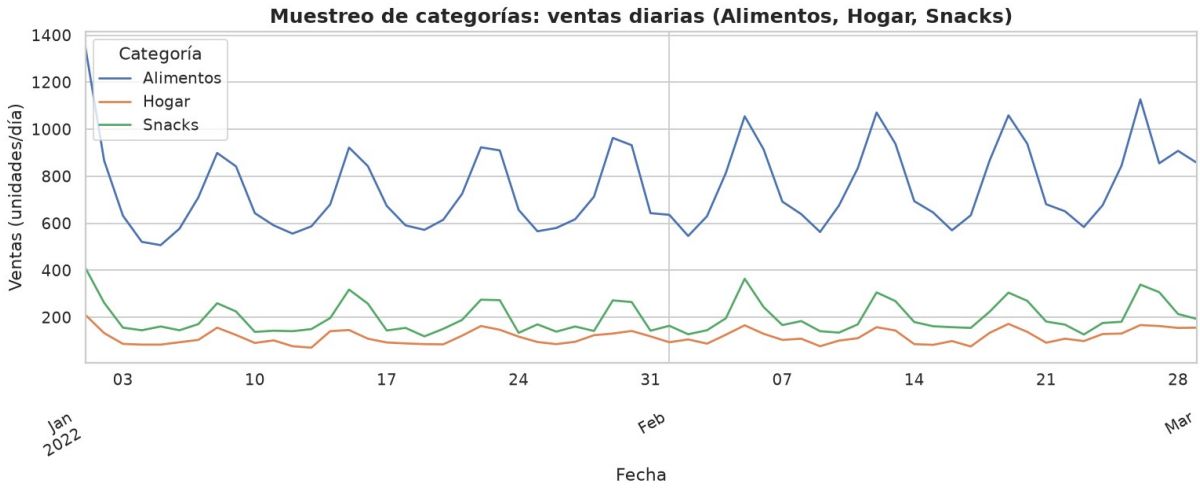
Comportamiento de las compras a lo largo del tiempo, organizado semana a semana durante los dos meses del período. Cada panel resume una semana y permite observar los cambios día a día y el patrón recurrente de fin de semana.






Muestreo de categorías de productos para facilitar la visualización del comportamiento conjunto a lo largo del tiempo.

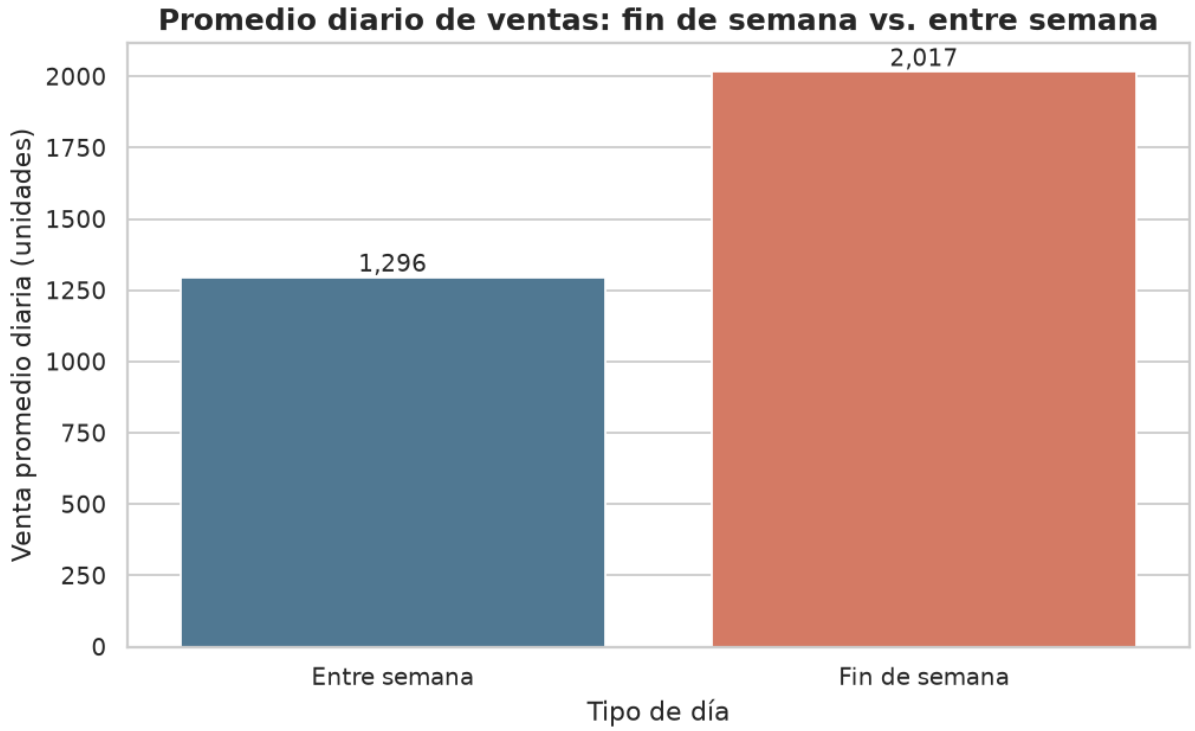



## 3. Variables creadas

Durante la ingeniería de características se crearon las siguientes variables temporales y de rezago:

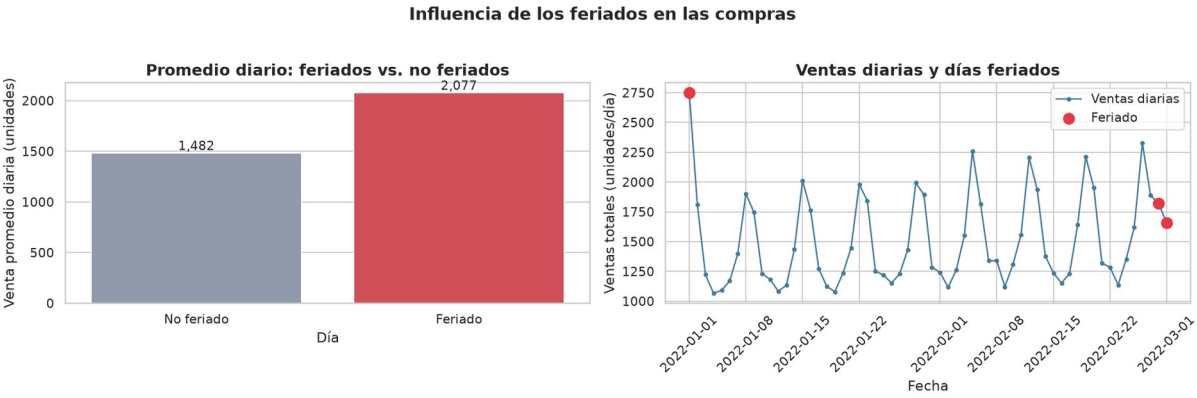
| Variable | Tipo | Descripción |
|---|---|---|
| **dia_semana / nombre_dia** | Numérica / texto | Día de la semana (0=Lunes … 6=Domingo). |
| **mes / dia_del_mes / anio** | Numérica | Componentes de la fecha para capturar estacionalidad. |
| **semana_iso / semana_del_periodo** | Numérica | Semana del año y semana dentro del período (1..N). |
| **es_fin_de_semana** | Indicador (0/1) | 1 si la venta es sábado o domingo; 0 en caso contrario. |
| **es_feriado** | Indicador (0/1) | 1 si la fecha es feriado nacional de Ecuador; 0 si no. |
| **tipo_dia** | Categórica (4 niveles) | Entre semana / Fin de semana / Feriado / Feriado (fin de semana). Sin pérdida: biyectiva con (`es_fin_de_semana`, `es_feriado`). |
| **ventas_dia_anterior / lag_7** | Numérica | Ventas del día anterior y de la semana anterior por producto. |
| **promedio_movil_7d** | Numérica | Promedio móvil de 7 días de las ventas por producto. |
| **dias_para_expirar** | Numérica | Días entre la venta y la fecha de expiración del producto. |

Efecto del fin de semana. El promedio diario de ventas es claramente mayor los sábados y domingos, lo que confirma el patrón semanal de compras.




| tipo_dia | venta_promedio_diaria | dias | ventas_totales |
|---|---|---|---|
| **Entre semana** | 1296.0 | 42 | 54434 |
| **Fin de semana** | 2016.7 | 18 | 36300 |

Efecto de los feriados. Se comparan los días feriados con los días normales y se señalan los feriados sobre la serie temporal.



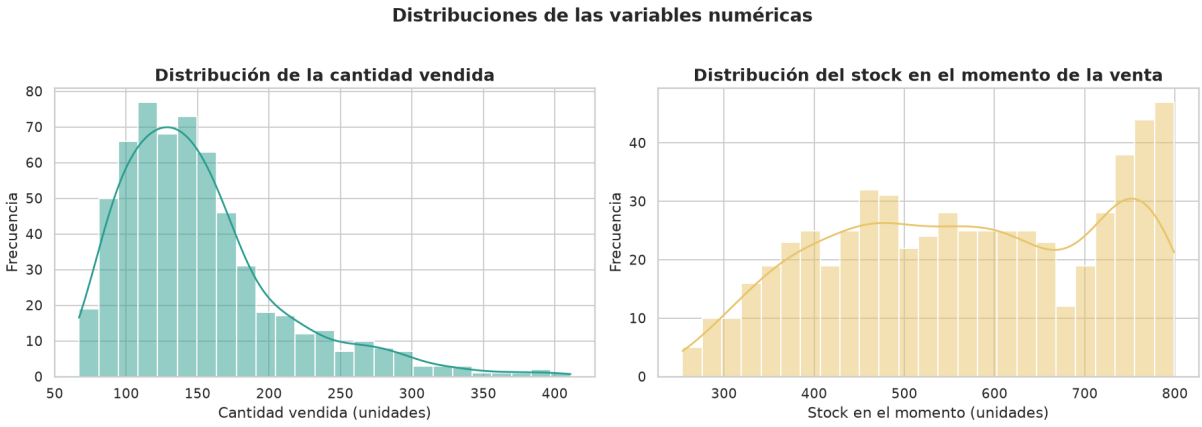

**Feriados presentes en el período (Ecuador):**

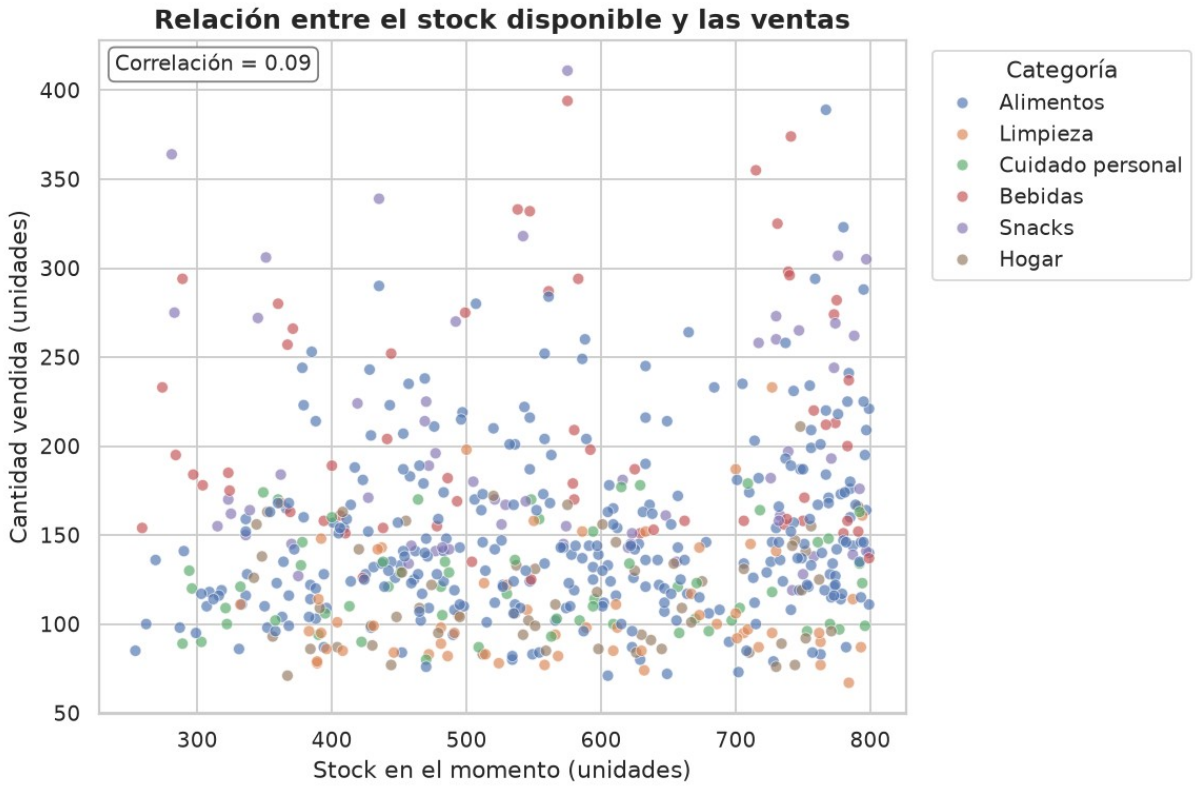
| fecha | dia | feriado |
|---|---|---|

| | | | |
|---|---|---|---|
| **2022-01-01** | Sábado | New Year's Day | |
| **2022-02-28** | Lunes | Carnival | |
| **2022-03-01** | Martes | Carnival | |

| **feriado** | venta_promedio_diaria | dias | ventas_totales |
|---|---|---|---|
| **No feriado** | 1482.5 | 57 | 84502 |
| **Feriado** | 2077.3 | 3 | 6232 |

Variables numéricas y relación stock–ventas:



## 4. Criterios del análisis y conclusiones

- Las figuras muestran patrones reconocibles: pico de ventas en fin de semana y en feriados, y una tendencia creciente leve durante el período.
- Cada figura incluye título y nombres en los ejes X e Y para su correcta interpretación.
- El negocio (tienda de barrio) explica la relevancia de las variables: fines de semana y feriados concentran más compras, por lo que el inventario debe reforzarse esos días.
- Las variables creadas permiten modelar la demanda futura respetando el calendario real.